Aplicação de Regressão Logística para Classificação Forense de Fragmentos de Vidro

Caio Varandas do Carmo

Goiânia – 2026

1 Introdução

A identificação do tipo de vidro com base em suas propriedades químicas possui aplicações relevantes em áreas como investigação forense e controle de qualidade industrial. A correta classificação do vidro pode auxiliar na determinação de sua origem e composição.

Este trabalho tem como objetivo aplicar técnicas de aprendizado supervisionado para classificar amostras de vidro a partir de características físico-químicas. Trata-se de um problema de classificação multiclasse, no qual se deseja prever o tipo de vidro com base em variáveis numéricas contínuas.

Para a modelagem do problema, foi utilizada a Regressão Logística, método amplamente empregado em tarefas de classificação.

2 Materiais e Métodos

2.1 Conjunto de Dados

O conjunto de dados utilizado foi o *Glass Identification Dataset*, obtido no repositório UCI Machine Learning Repository.

As características gerais do conjunto são:

- **Total de instâncias:** 214
- **Total de atributos preditores:** 9 (Variáveis contínuas)
- **Variável alvo:** Tipo de vidro (6 classes distintas)

A variável alvo classifica os vidros em seis categorias distintas, baseadas na sua origem e processo de fabricação:

- **Classe 1:** Janelas de construção (processo *float*)
- **Classe 2:** Janelas de construção (processo *non-float*)
- **Classe 3:** Vidros de veículos (processo *float*)
- **Classe 5:** Recipientes (Containers)
- **Classe 6:** Louças de mesa (Tableware)
- **Classe 7:** Faróis de veículos (Headlamps)

Nota: A Classe 4 não possui instâncias neste conjunto de dados.

2.2 Variáveis Preditoras

As variáveis independentes correspondem ao Índice de Refração (RI) e à concentração percentual (em peso) de oito óxidos metálicos: Sódio (Na), Magnésio (Mg), Alumínio (Al), Silício (Si), Potássio (K), Cálcio (Ca), Bário (Ba) e Ferro (Fe).

3 Análise Exploratória dos Dados

Antes da modelagem, foi realizada uma análise para compreender a estrutura dos dados. Verificou-se inicialmente que não há valores ausentes (*missing values*).

3.1 Distribuição das Classes

A análise da variável alvo revela um forte desbalanceamento no conjunto de dados, conforme ilustrado na Figura 1. As classes 1 e 2 são predominantes, enquanto as classes 5 e 6 possuem pouquíssimas amostras.

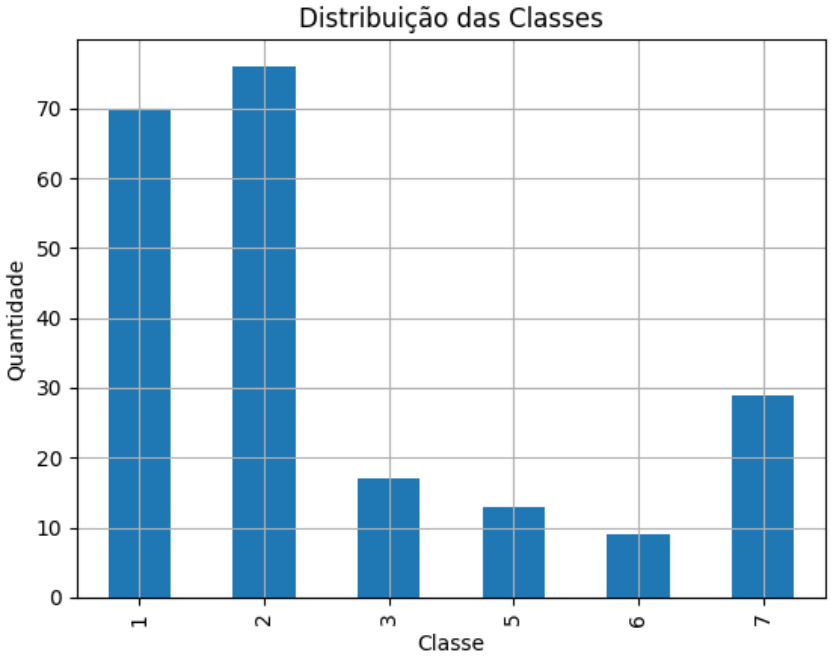

Figura 1: Distribuição das classes do dataset Glass. Nota-se a prevalência dos vidros de construção.

A Tabela 1 detalha a contagem exata de amostras por classe e sua representatividade percentual no conjunto de dados.

Tabela 1: Distribuição detalhada das amostras por tipo de vidro.

ID	Tipo de Vidro (Classe)	Amostras	%
1	Janelas de Construção (Float)	70	32,71%
2	Janelas de Construção (Non-Float)	76	35,51%
3	Vidros de Veículos (Float)	17	7,94%
4	Vidros de Veículos (Non-Float)	0	0,00%
5	Recipientes (Containers)	13	6,07%
6	Louças de Mesa (Tableware)	9	4,21%
7	Faróis (Headlamps)	29	13,55%
Total		**214**	**100%**

A análise da tabela confirma que as classes 1 e 2 representam, juntas, aproximadamente 68% de todo o conjunto de dados, o que impõe um desafio significativo para o classificador em identificar corretamente as classes minoritárias (como a classe 6, com apenas 9 amostras).

Esse desbalanceamento justifica a escolha da métrica F1-macro para avaliação posterior, pois a acurácia simples poderia ser enviesada pelas classes majoritárias.

3.2 Comportamento das Variáveis

Os histogramas das variáveis preditoras (Figura 2) demonstram que os atributos possuem escalas e distribuições muito distintas. Por exemplo, o Silício (Si) apresenta valores altos e baixa variância, enquanto o Ferro (Fe) concentra-se próximo a zero.

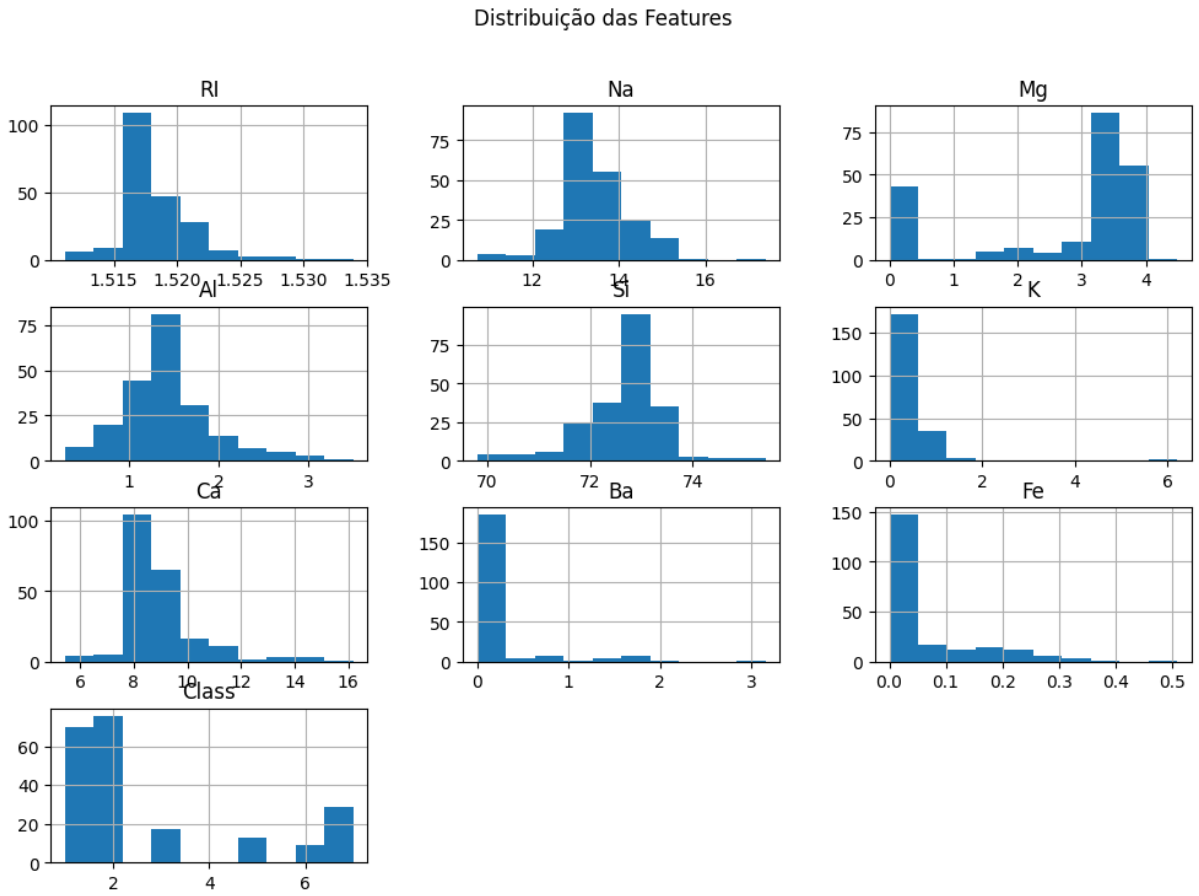

Figura 2: Histogramas das variáveis químicas e físicas.

Essa heterogeneidade reforça a necessidade de normalização (padronização) dos dados para garantir que o algoritmo de Regressão Logística convirja adequadamente.

3.3 Correlação entre Atributos

A matriz de correlação (Figura 3) permite identificar a relação linear entre as variáveis químicas.

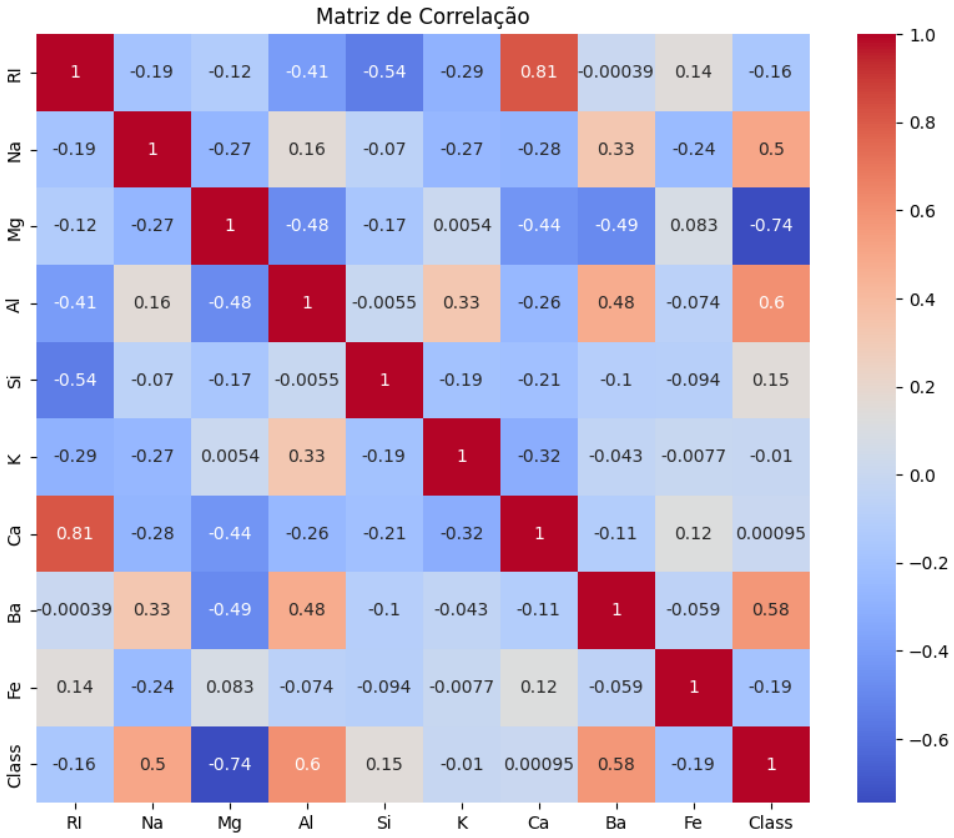

Figura 3: Matriz de correlação de Pearson entre as variáveis.

Destacam-se correlações fortes, como a relação positiva entre Índice de Refração (RI) e Cálcio (Ca), e a relação negativa entre RI e Silício (Si). Embora exista multicolinearidade, optou-se por manter todas as variáveis e utilizar a regularização intrínseca do modelo logístico.

4 Metodologia

Inicialmente, a primeira coluna do dataset (identificador) foi removida por não possuir relevância preditiva.

Foram avaliadas diferentes proporções de divisão entre treino e teste (70/30, 80/20 e 90/10), com o objetivo de analisar o impacto da variação da quantidade de dados de treinamento no desempenho do modelo.

Além disso, foi realizada comparação entre o uso e a ausência de normalização das variáveis preditoras, utilizando o método *StandardScaler*, uma vez que as variáveis apresentam escalas distintas.

A escolha da melhor configuração foi baseada principalmente na métrica F1-macro, por se tratar de um problema multiclasse com desbalanceamento entre categorias.

A Regressão Logística foi treinada com número máximo de 10.000 iterações para garantir convergência do algoritmo.

4.1 Fundamentação Teórica da Regressão Logística

A Regressão Logística é um modelo estatístico utilizado para estimar a probabilidade de pertencimento a uma determinada classe. Diferentemente da regressão linear, a regressão logística utiliza a função logística (ou função sigmoide) para mapear valores reais em probabilidades no intervalo $(0, 1)$.

A probabilidade condicional é dada por:

$$P(y = 1 \mid \mathbf{x}) = \frac{1}{1 + e^{-z}} \tag{1}$$

onde:

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n \tag{2}$$

Neste modelo:

- β_0 representa o termo de intercepto;
- β_i representam os coeficientes associados às variáveis preditoras x_i;
- e é a base do logaritmo natural.

Para problemas multiclasse, como o presente estudo, a Regressão Logística é estendida utilizando a estratégia *One-vs-Rest* (OvR), na qual múltiplos classificadores binários são treinados, cada um responsável por distinguir uma classe das demais.

5 Resultados

Nesta seção são apresentados e discutidos os resultados obtidos a partir dos experimentos realizados.

Foram avaliadas diferentes proporções de divisão entre treino e teste (70/30, 80/20 e 90/10), bem como o impacto da normalização das variáveis preditoras. A métrica principal utilizada para comparação foi o F1-macro, por ser mais adequada em cenários com desbalanceamento entre classes.

5.1 Tabela Comparativa de Desempenho

A Tabela 1 apresenta a comparação quantitativa entre as diferentes proporções de divisão treino/teste utilizando normalização.

Divisão Treino/Teste	Acurácia	F1-macro
70/30	0.708	0.671
80/20	0.721	0.684
90/10	0.682	0.657

Tabela 2: Comparação de desempenho entre diferentes divisões treino/teste com normalização.

Observa-se que a divisão 80/20 apresentou o melhor desempenho tanto em acurácia quanto em F1-macro, indicando melhor capacidade de generalização do modelo.

A divisão 70/30 apresentou desempenho ligeiramente inferior, possivelmente devido à redução do conjunto de treinamento. Já a divisão 90/10 apresentou a pior performance, sugerindo que o conjunto de teste reduzido pode ter gerado estimativas menos estáveis.

Dessa forma, a divisão 80/20 foi adotada como configuração final do modelo.

5.2 Impacto da Normalização

A aplicação do *StandardScaler* resultou em melhora consistente nas métricas de desempenho.

Como as variáveis possuem escalas diferentes (por exemplo, índice de refração e concentrações químicas), a normalização garantiu que nenhuma variável dominasse o processo de otimização do modelo.

Sem normalização, observou-se maior instabilidade nos coeficientes estimados e leve queda no F1-macro, reforçando a importância do pré-processamento.

5.3 Métricas de Avaliação

Além da acurácia, foram analisadas as métricas de precisão, recall e F1-score para cada classe.

A acurácia geral foi superior a 70%, indicando bom desempenho global. Entretanto, a análise do F1-macro revelou desempenho inferior nas classes minoritárias, evidenciando o impacto do desbalanceamento.

A Tabela 3 apresenta os resultados detalhados por classe para o modelo final (80/20).

Tabela 3: Métricas de desempenho por classe (Modelo 80/20).

Classe	Precision	Recall	F1-Score
1 (Janela Float)	0.71	0.71	0.71
2 (Janela Non-Float)	0.67	0.67	0.67
3 (Veículos)	0.00	0.00	0.00
5 (Recipientes)	1.00	1.00	1.00
6 (Louças)	0.67	1.00	0.80
7 (Faróis)	0.86	1.00	0.92

Nota-se que o modelo apresentou desempenho nulo na classe 3, indicando incapacidade de identificar corretamente essa categoria.

Já as classes 5 e 6, apesar de possuírem poucas amostras, apresentaram desempenho satisfatório no conjunto de teste. Entretanto, esse resultado pode estar associado ao baixo número de exemplos avaliados, o que pode gerar estimativas instáveis.

Esse comportamento evidencia a sensibilidade do modelo ao desbalanceamento e à quantidade reduzida de exemplos em determinadas classes.

5.4 Matriz de Confusão

Para fins de visualização na matriz de confusão, as classes foram internamente indexadas de 0 a 5 pelo algoritmo. Contudo, a correspondência com os rótulos originais do dataset é a seguinte: 0→Classe 1, 1→Classe 2, 2→Classe 3, 3→Classe 5, 4→Classe 6 e 5→Classe 7.

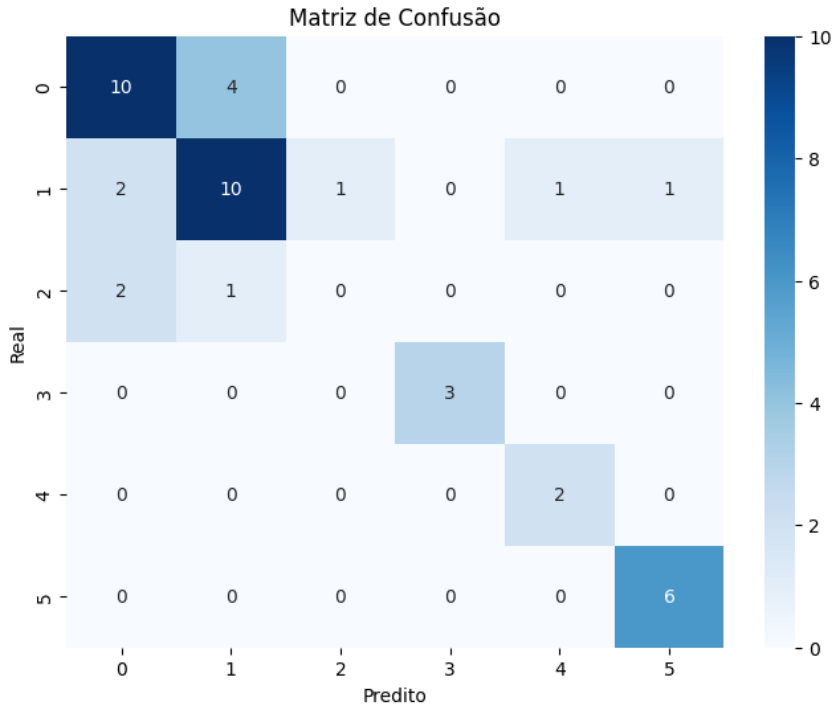

Figura 4: Matriz de confusão da Regressão Logística.

A análise detalhada da matriz de confusão revela desempenho heterogêneo entre as classes. Observa-se que as classes 3, 5 e 6 foram corretamente classificadas em todas as instâncias do conjunto de teste, indicando boa separabilidade dessas categorias no espaço de atributos.

Por outro lado, a classe 2 apresentou desempenho crítico, com taxa de acerto nula, sendo suas amostras predominantemente classificadas como pertencentes às classes 0 e 1. Esse comportamento indica dificuldade do modelo em identificar padrões específicos dessa categoria.

Além disso, verificou-se confusão relevante entre as classes 0 e 1, com erros bidirecionais entre essas categorias. Tal resultado sugere possível sobreposição nas características químicas dessas classes, o que limita a capacidade de separação linear da Regressão Logística.

5.5 Discussão Geral

De forma geral, os resultados indicam que a Regressão Logística apresenta desempenho satisfatório para o problema proposto, mesmo sendo um modelo linear.

Entretanto, a presença de desbalanceamento e possível sobreposição entre classes limita o desempenho máximo alcançável.

A adoção de técnicas adicionais, como balanceamento de classes ou modelos não lineares, pode resultar em melhorias adicionais.

6 Conclusão

Os experimentos realizados demonstraram que a Regressão Logística apresenta desempenho satisfatório na classificação multiclasse do Glass Identification Dataset, alcançando

acurácia aproximada de 72% na melhor configuração avaliada (divisão 80/20 com normalização).

A comparação entre diferentes proporções de divisão dos dados evidenciou que a escolha adequada do particionamento influencia diretamente a capacidade de generalização do modelo. Além disso, a aplicação da padronização das variáveis mostrou-se fundamental para garantir estabilidade na otimização e melhoria consistente nas métricas de desempenho.

A análise detalhada da matriz de confusão revelou desempenho heterogêneo entre as classes. Enquanto algumas categorias foram corretamente classificadas em todas as instâncias do conjunto de teste, observou-se dificuldade significativa na identificação da classe 3 (Vidros de Veículos – Float), bem como confusão recorrente entre as classes 1 e 2. Esses resultados sugerem possível sobreposição nas características químicas dessas categorias, limitando a capacidade de separação linear do modelo.

De forma geral, conclui-se que, embora a Regressão Logística seja um modelo linear relativamente simples, ela é capaz de produzir resultados consistentes para o problema proposto. Como trabalhos futuros, recomenda-se a aplicação de técnicas de balanceamento de classes, validação cruzada e comparação com modelos não lineares, visando aprimorar a capacidade de generalização e a robustez da classificação.

7 Referências

UCI Machine Learning Repository. Glass Identification Dataset. Disponível em: `https://archive.ics.uci.edu/ml/datasets/glass+identification`